Нагорный Олег

Введение в визуализацию данных с Sea...

Courses / Introduction to Data Science / Введение в визуализацию данных с Seaborn

```
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
%config InlineBackend.figure_format = 'svg'
```

Для демонстрации инстументов визуализации используем набор данных о чаевых.

```
tips = sns.load_dataset('tips')
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

Визуализация распределения

Seaborn — это более высокоуровневое API на базе библиотеки matplotlib. Seaborn содержит более адекватные дефолтные настройки оформления графиков. Если просто добавить в код import seaborn, то картинки станут гораздо симпатичнее. Также в библиотеке есть достаточно сложные типы визуализации, которые в matplotlib потребовали бы большого количество кода.

Для визуализации распределения метрических переменных используются следующие типы графиков:

- distplot
- jointplot
- rugplot
- kdeplot

Можно таже визуализировать относительные распределения между парами переменных при помощи методов:

- PairGrid
- pairplot
- FacetGrid

distplot

distplot одновременно показывает гистограмму и график плотности распределения.

```
sns.distplot(tips['total_bill']);
```

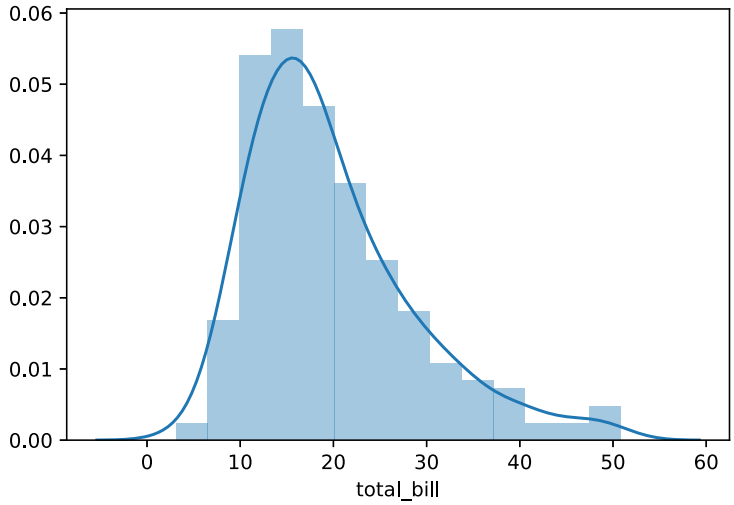

Можно оставить только гистограмму:

```
sns.distplot(tips['total_bill'], kde=False, bins=30);
```

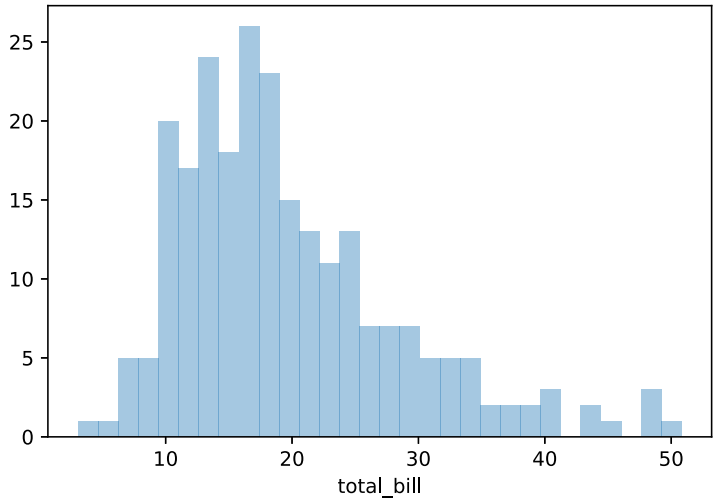

jointplot

Функция jointplot() показывает совместное распределение по двум переменным. Она имеет параметр **kind** который может принимать следующие значения:

- “scatter”
- “reg”
- “resid”
- “kde”
- “hex”

```
sns.jointplot(x='total_bill', y='tip', data=tips, kind='scatter');
```

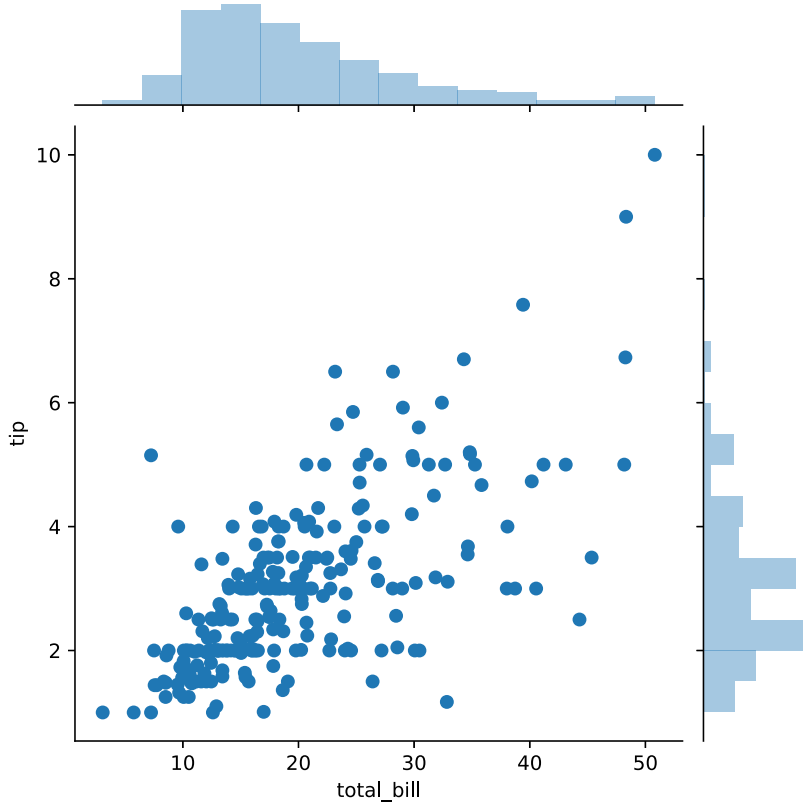


```
sns.jointplot(x='total_bill',y='tip',data=tips,kind='hex');
```

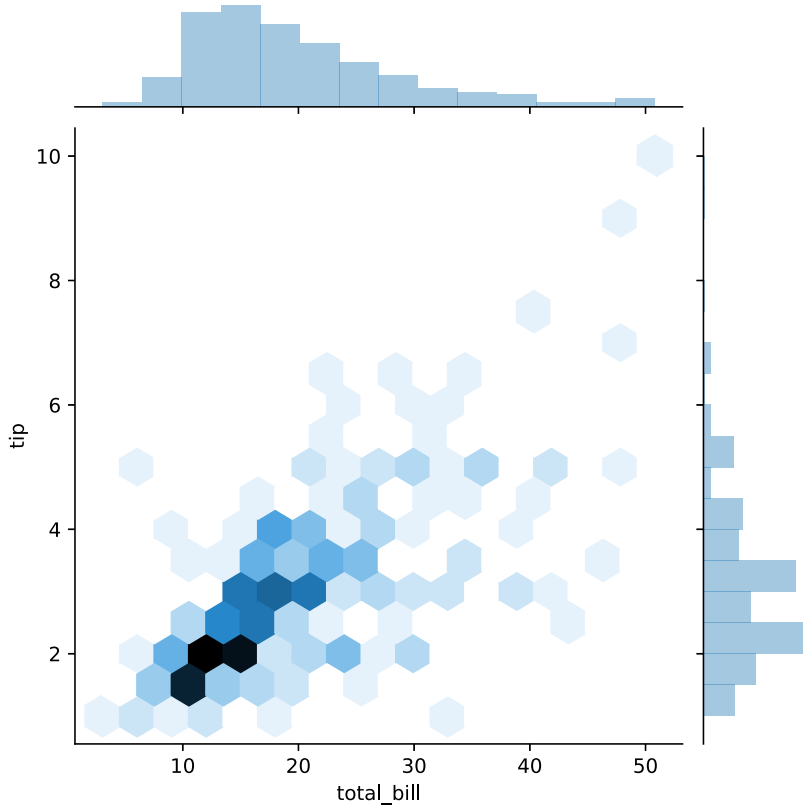


```
sns.jointplot(x='total_bill', y='tip', data=tips, kind='reg');
```

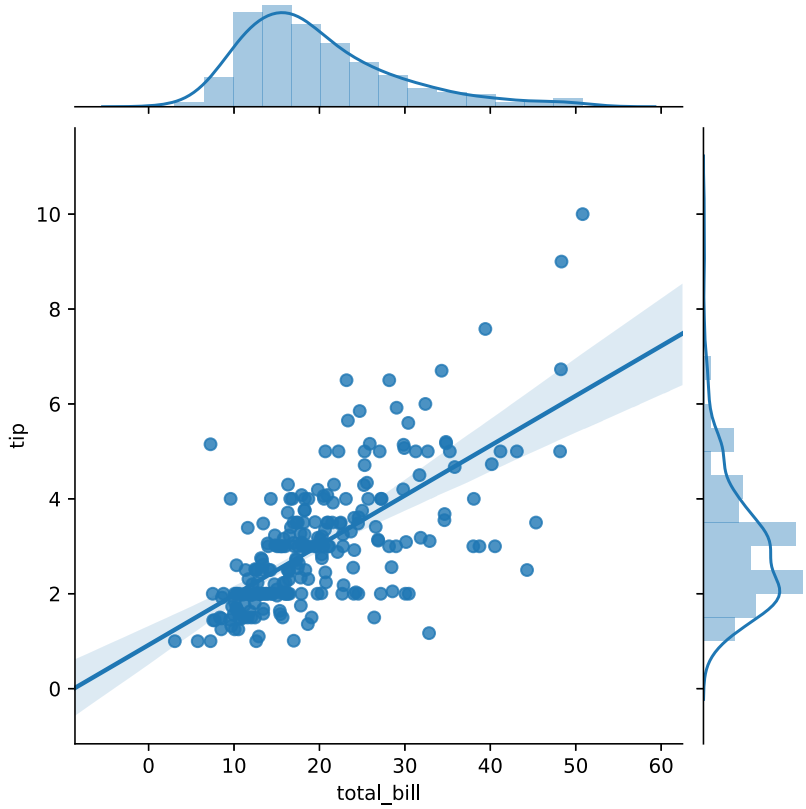

pairplot

pairplot показывает отношения между всеми парами переменных.

```
sns.pairplot(tips);
```

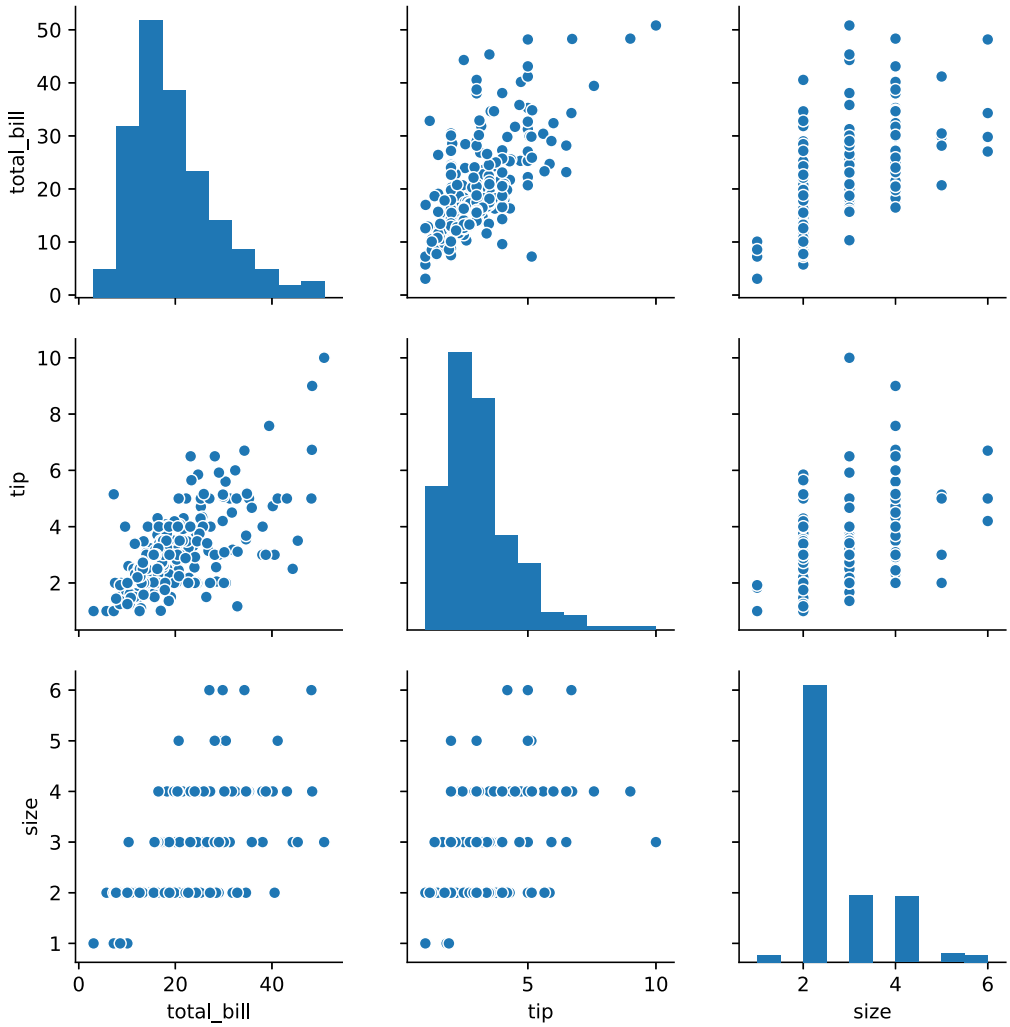


```
sns.pairplot(tips, hue='sex', palette='Set1');
```

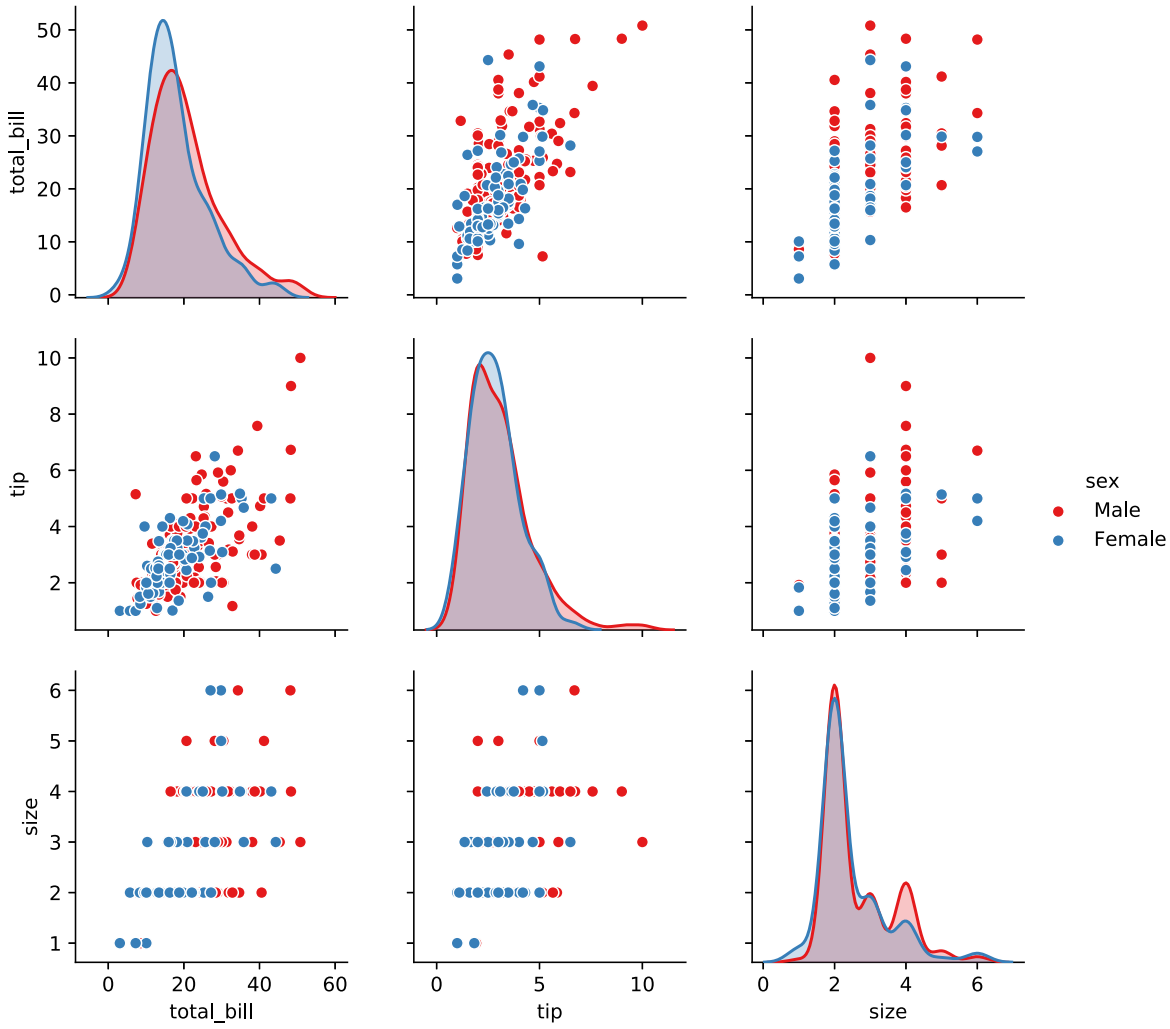

По сути pairplot — это упрощённая версия другой функции, которая называется PairGrid.

```
sns.PairGrid(tips);
```

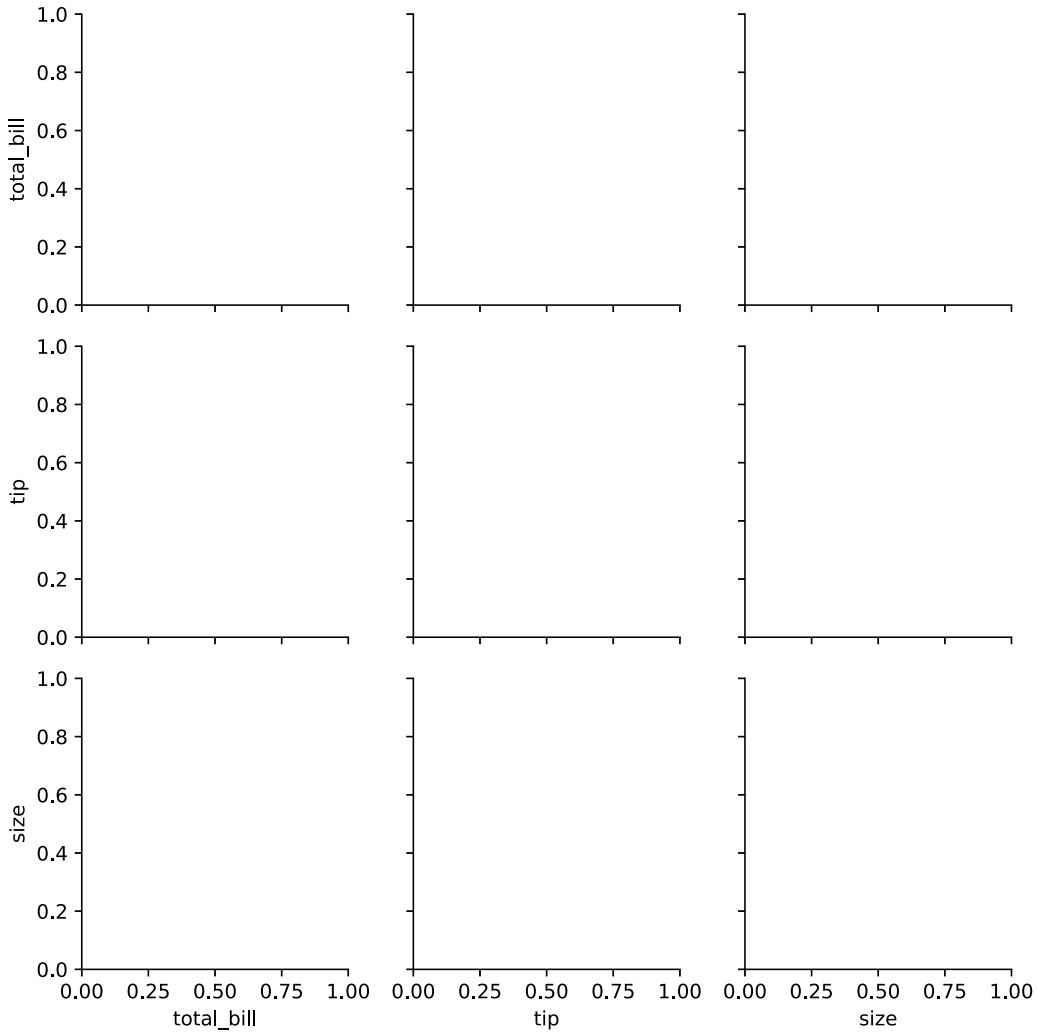


```
g = sns.PairGrid(tips)
g.map(plt.scatter);
```

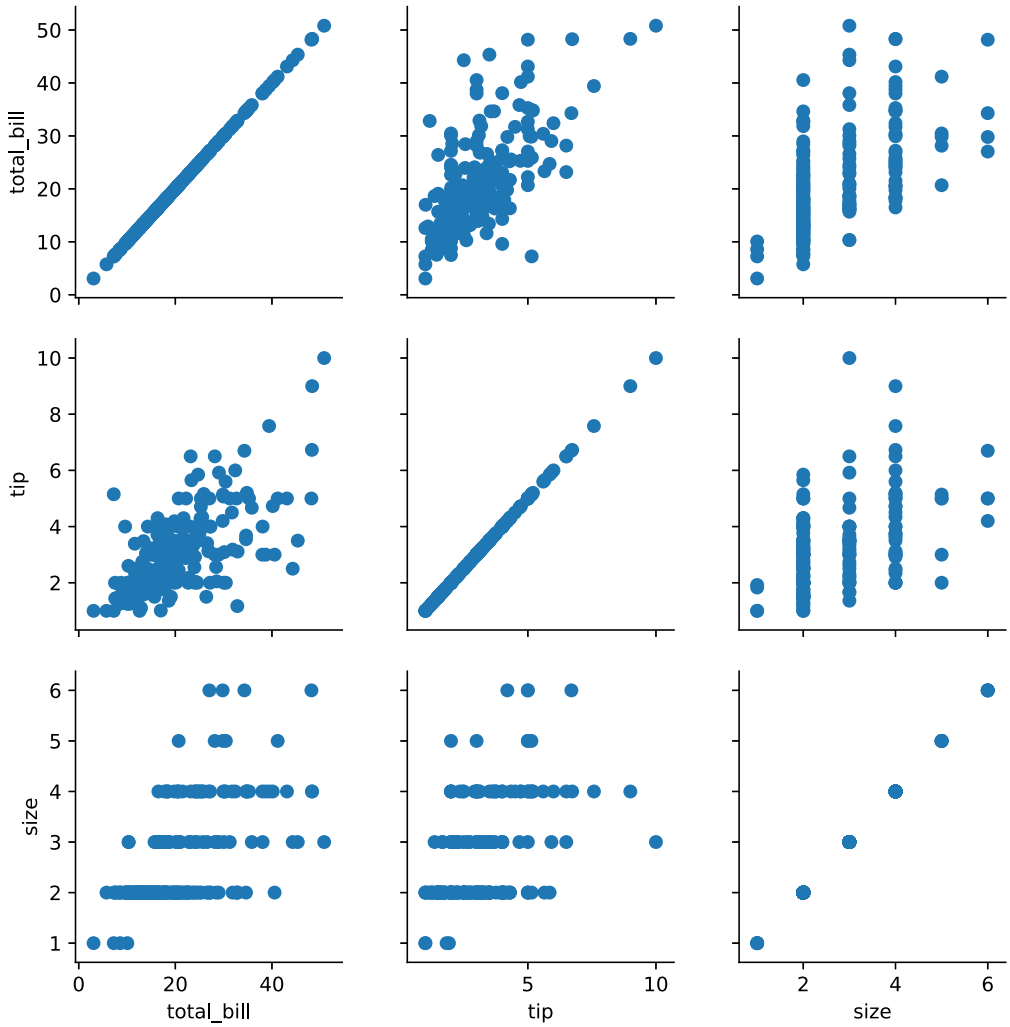


```
g = sns.PairGrid(tips)
g.map_diag(plt.hist)
g.map_upper(plt.scatter)
g.map_lower(sns.kdeplot);
```

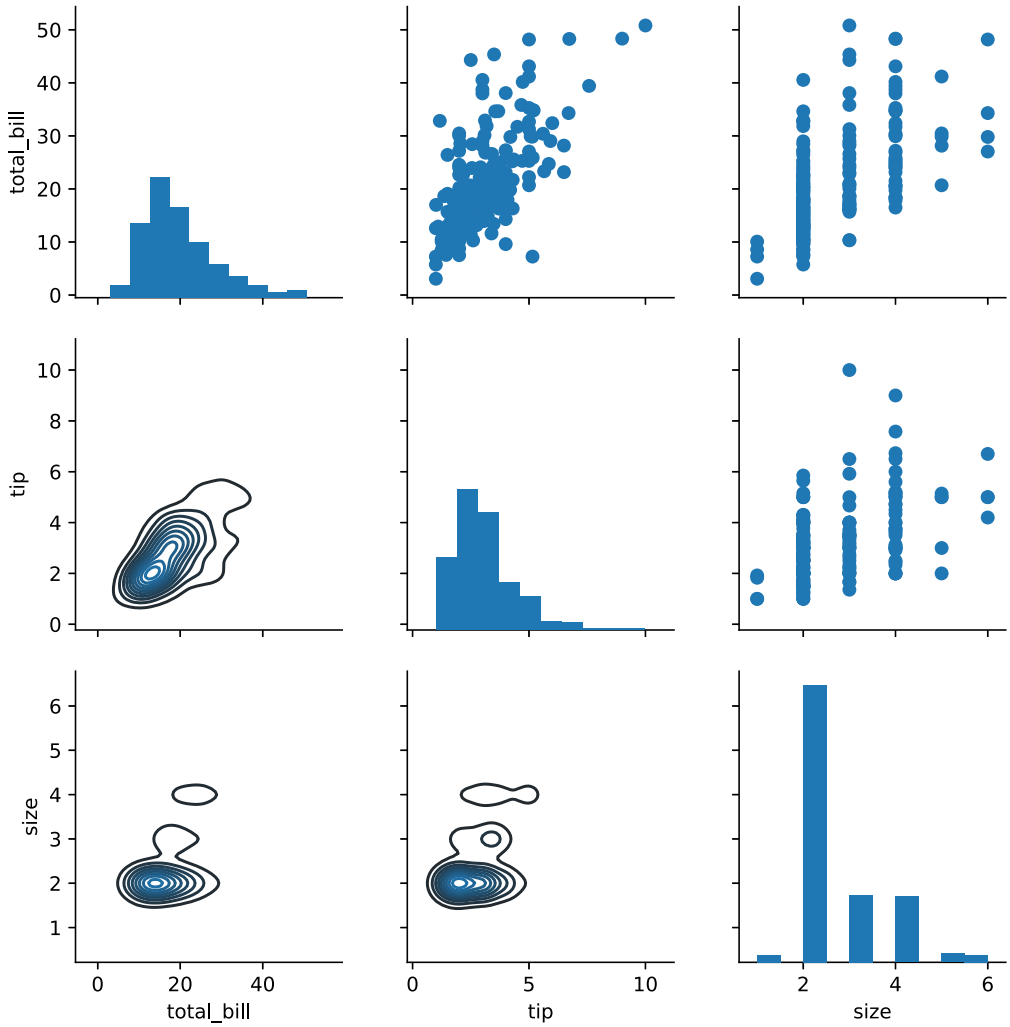

Плотность распределения по двум переменным даёт нам градиент. Градиент — вектор, своим направлением указывающий направление наибольшего возрастания некоторой величины φ, значение которой меняется от одной точки пространства к другой (скалярного поля), а по величине (модулю) равный скорости роста этой величины в этом направлении.

```
sns.kdeplot(tips['total_bill'], tips['tip']);
```

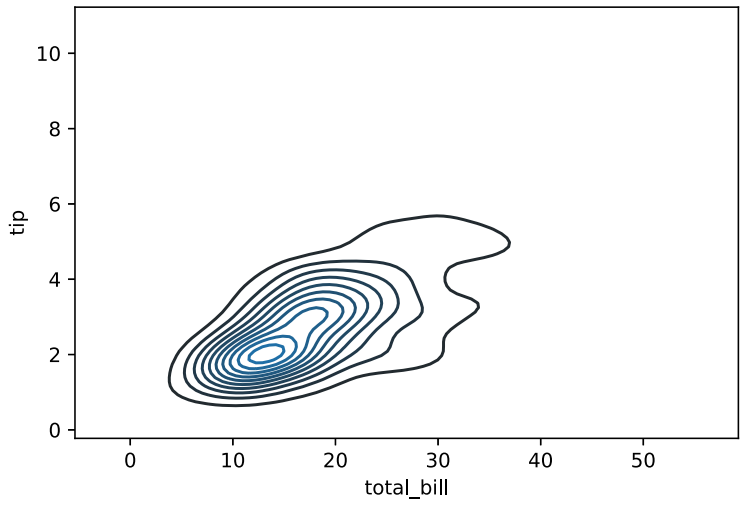

Facet Grid

Facet Grid позволяет визуализировать совместное распределение отдельных признаков нескольких переменных.

```
g = sns.FacetGrid(tips, col="time", row="smoker");
```

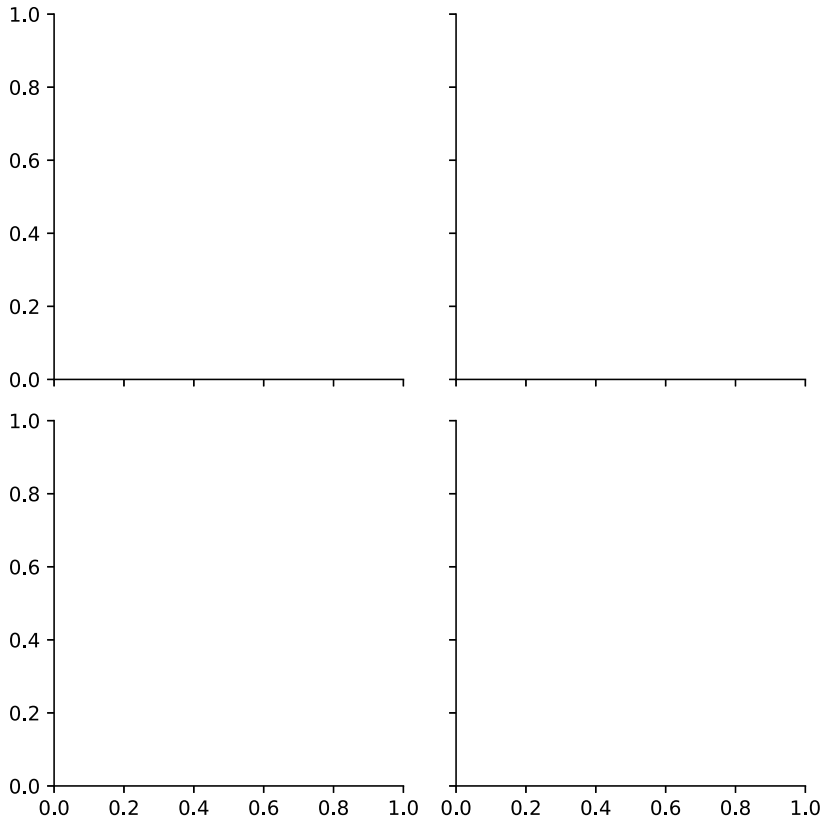


```
g = sns.FacetGrid(tips, col="time", row="smoker")
g = g.map(plt.hist, "total_bill");
```

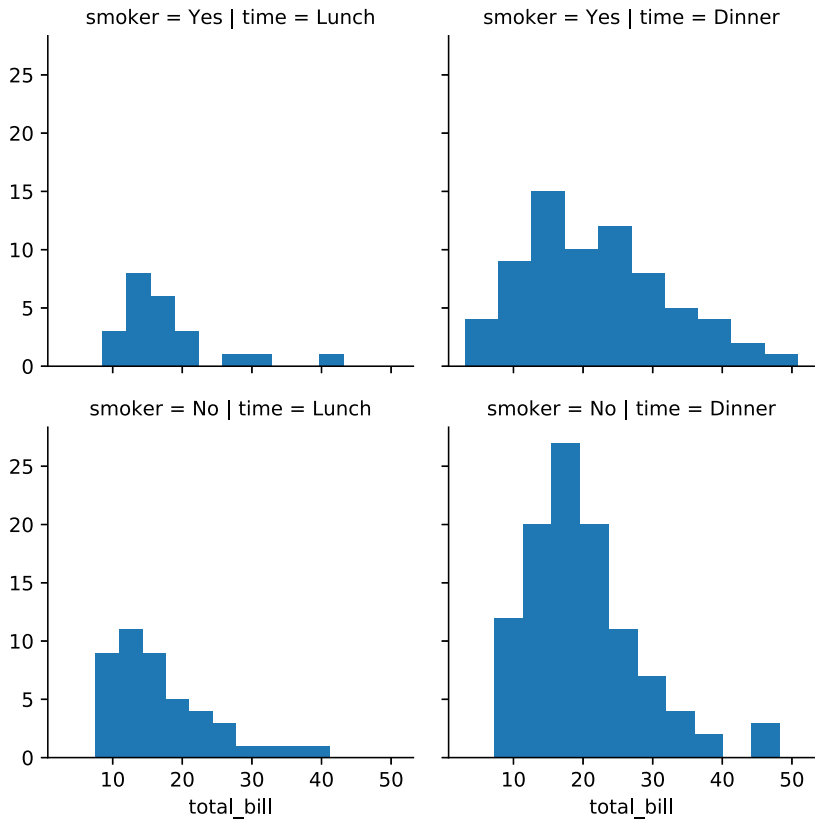

```
g = sns.FacetGrid(tips, col="time", row="smoker", hue='sex')
g = g.map(plt.scatter, "total_bill", "tip").add_legend();
```

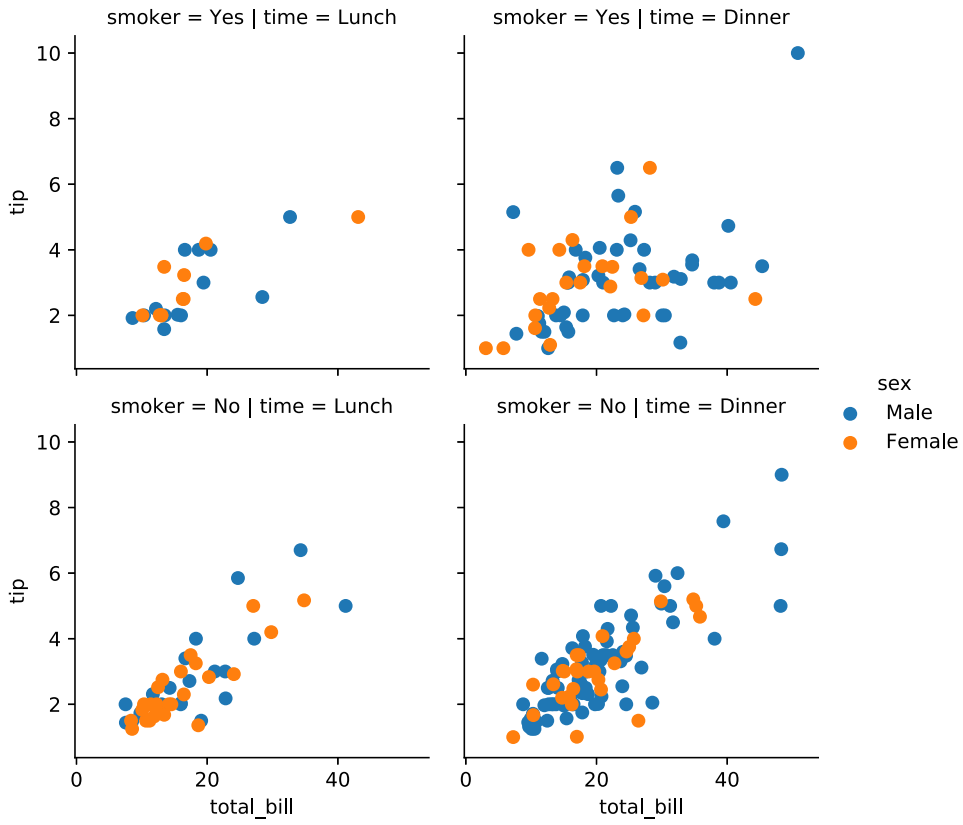

rugplot

rugplot показывает то же, что и график плотности распределения, только в одномерной форме. Чем плотнее расположены линии, тем выше плотность. Лучше использовать его совместно с другими видами графиков.

```
sns.kdeplot(tips['tip'])
sns.rugplot(tips['tip']);
```

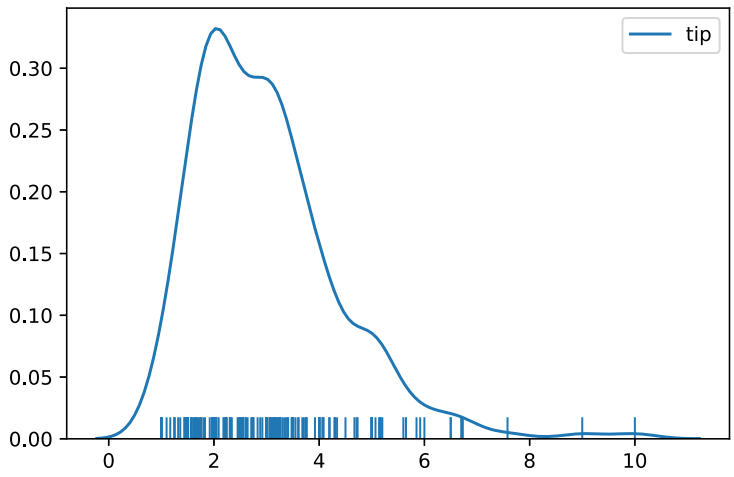

Визуализация категориальных данных

В seaborn встроены функции для визуализации категориальных данных в следующих форматах:

- factorplot
- boxplot
- violinplot
- stripplot
- swarmplot
- barplot
- countplot

В качестве тестового набора данных возьмём данные о чаевых, которые поставляются вместе с seaborn:

barplot

Первый тип визуализации — это barplot. У нас есть категориальная переменная и её цифровое значение. Барплот аггрегирует данные по значениям категориальной переменной и применяет определённую функцию к значениям соответсвующих групп цифровой переменной. По умолчанию эта функция — среднее.

```
sns.barplot(x='sex', y='total_bill', data=tips);
```

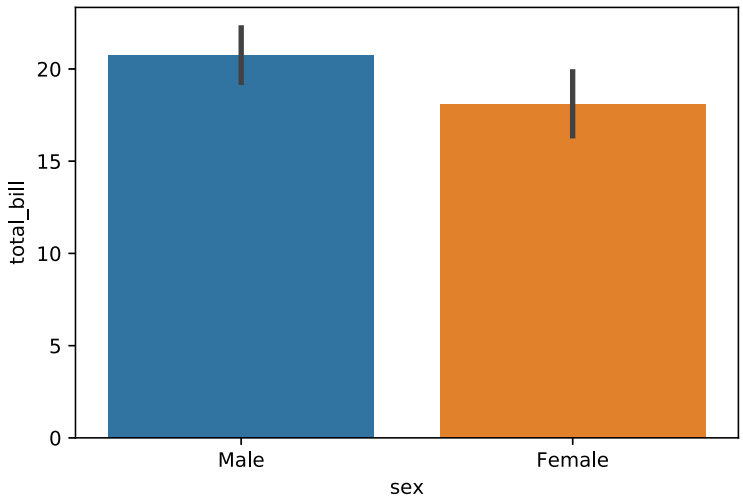

Эту функцию можно изменить в аргументе `estimator` :

```
sns.barplot(x='sex', y='total_bill', data=tips, estimator=len)
sns.countplot(x='sex', data=tips);
```

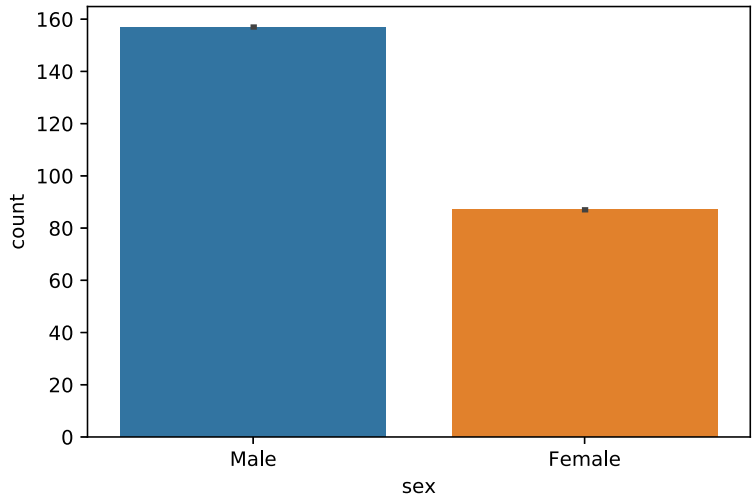

Здесь мы считаем стандартное отклоенение.

countplot

То же самое, что и барплот, только функция уже явно задана, и она считает количество значений в каждой категории.

```
sns.countplot(x='sex', data=tips);
```

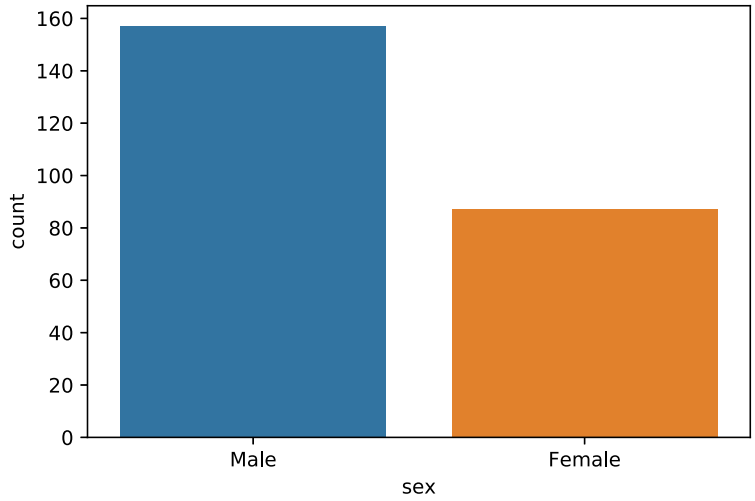

Промежуточное задание 1. Постройте при помощи barplot точно также график, как с помощью countplot.

boxplot и violinplot

Эти два графика используются для изучения формы распределения.

boxplot

Другое название boxplot — ящик с усами или диаграмма размаха. Он был разработан Джоном Тьюки в 1970-х годах.

Такой вид диаграммы в удобной форме показывает медиану (или, если нужно, среднее), нижний и верхний квартили, минимальное и максимальное значение выборки и выбросы. Несколько таких ящиков можно нарисовать бок о бок, чтобы визуально сравнивать одно распределение с другим; их можно располагать как горизонтально, так и вертикально. Расстояния между различными частями ящика позволяют определить степень разброса (дисперсии) и асимметрии данных и выявить выбросы.

```
sns.boxplot(x="day", y="total_bill", data=tips, palette='rainbow');
```

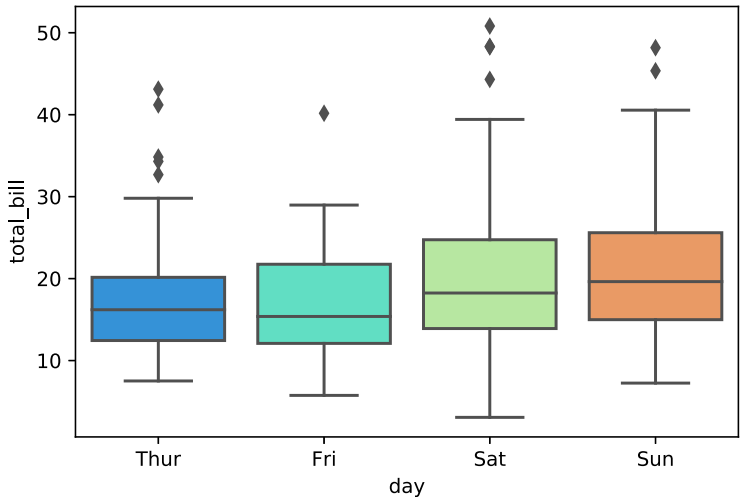


```
sns.boxplot(data=tips, palette='rainbow', orient='h');
```

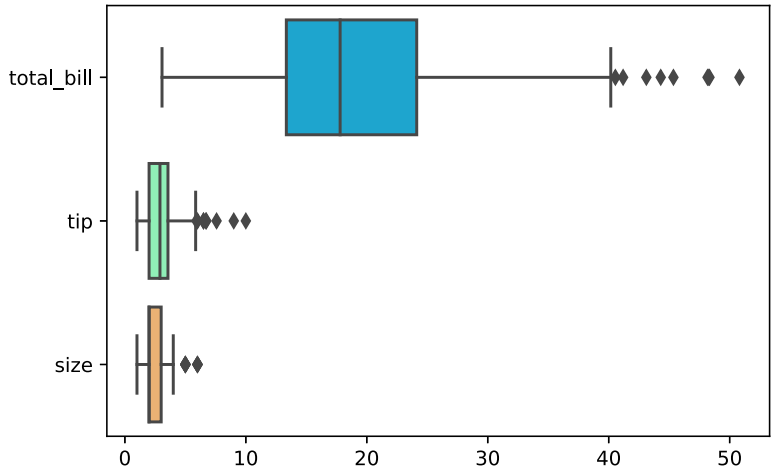

Можно ввести в график третье измерение:

```
sns.boxplot(
    x="day", y="total_bill", hue="smoker", data=tips, palette="coolwarm");
```

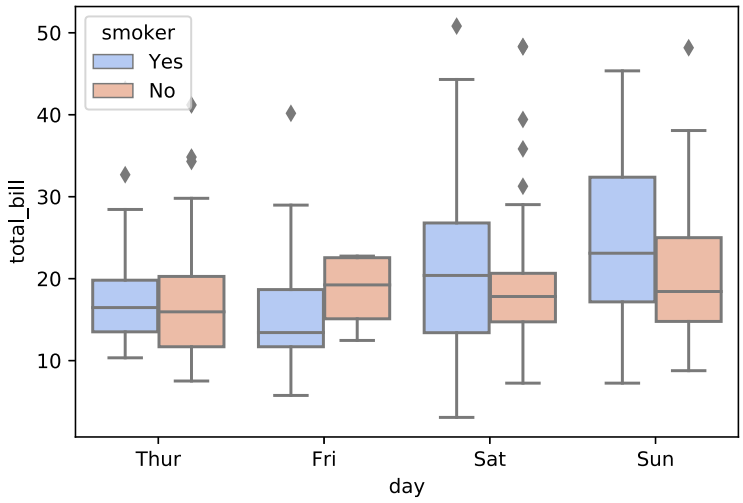

violinplot

Выполняет ту же функцию, что и boxplot. По сути это два повёрнутые на 90 и -90 градусов графика плотности распределения, слипшиеся друг с другом.

```
sns.violinplot(x="day", y="total_bill", data=tips, palette='rainbow');
```

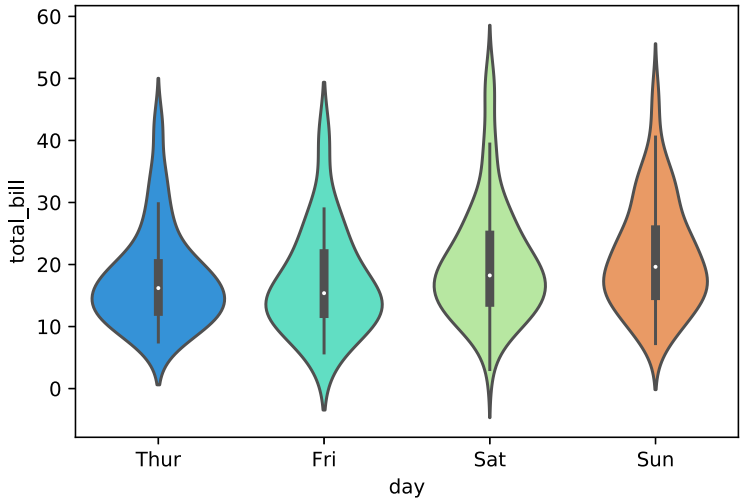


```
sns.violinplot(x="day", y="total_bill", data=tips, hue='sex', palette='Set1');
```

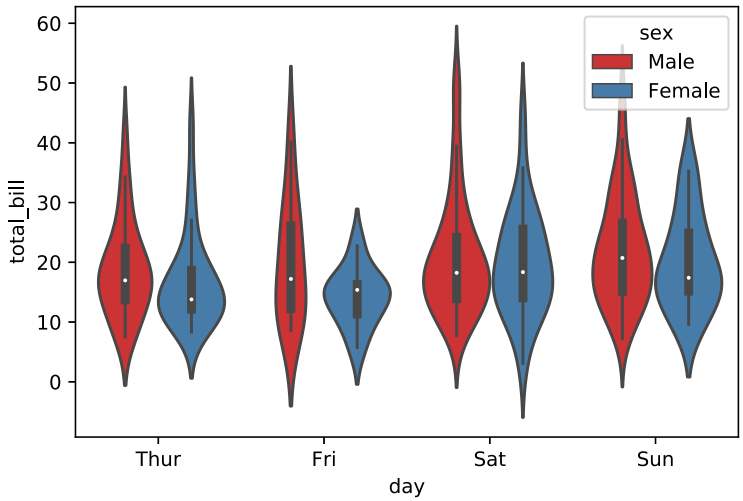

```
sns.violinplot(
    x="day", y="total_bill", data=tips, hue='sex', split=True, palette='Set1');
```

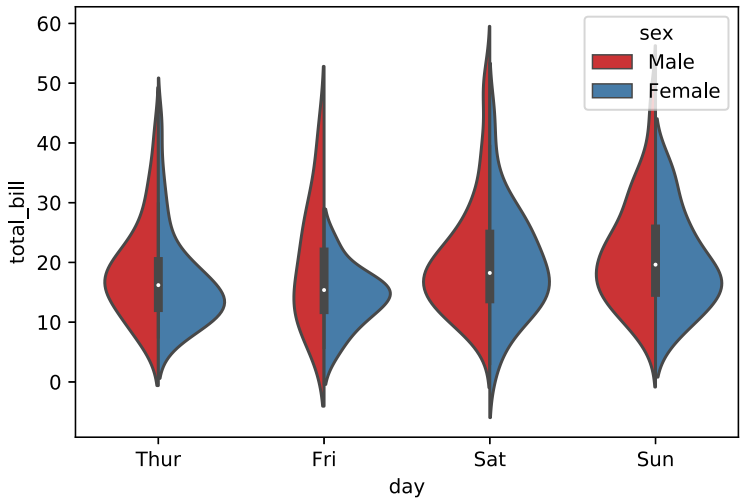

stripplot и swarmplot

stripplot рисует диаграмму рассеяния, состоящую из одной категориальной переменной. Его можно использовать как самостоятельную фигуру, но лучше сочетать с другими графиками.

```
sns.stripplot(x="day", y="total_bill", data=tips);
```

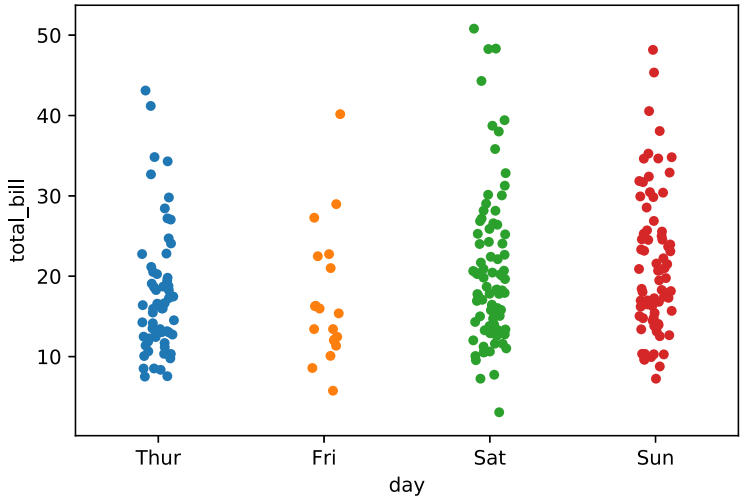


```
sns.stripplot(x="day", y="total_bill", data=tips, jitter=True);
```

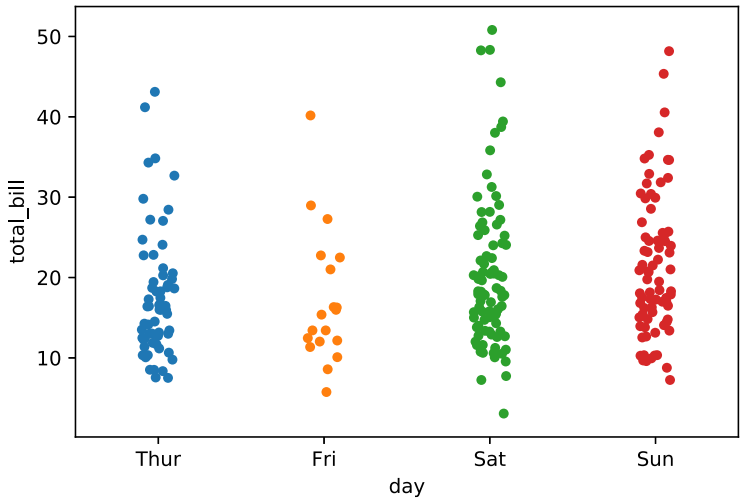


```
sns.stripplot(
    x="day", y="total_bill", data=tips, jitter=True, hue='sex', palette='Set1');
```

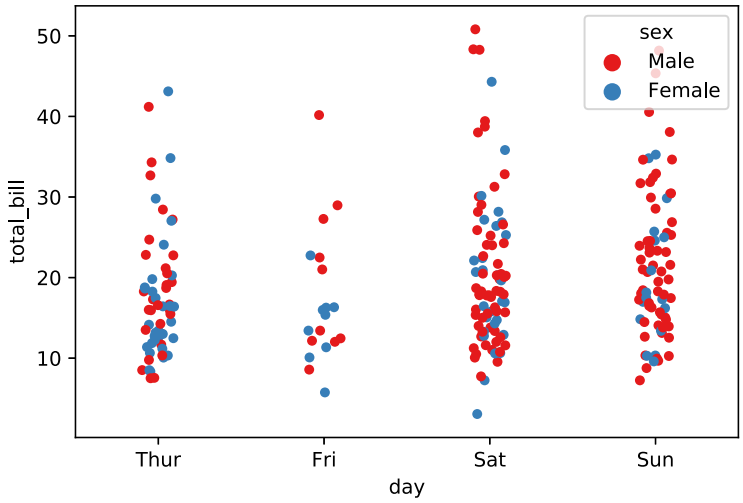


```
sns.stripplot(
    x="day",
    y="total_bill",
    data=tips,
    jitter=True,
    hue='sex',
    palette='Set1',
    dodge=True);  # раньше назывался split
```

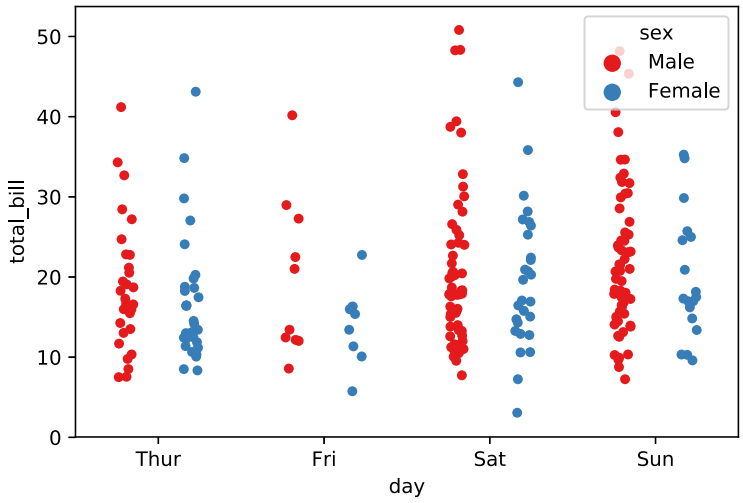

Swarmplot представляет собой ровно то же самое, с той лишь разницей, что точки не накладываются друг на друга.

```
sns.swarmplot(
    x="day", y="total_bill", hue='sex', data=tips, palette="Set1", dodge=True);
```

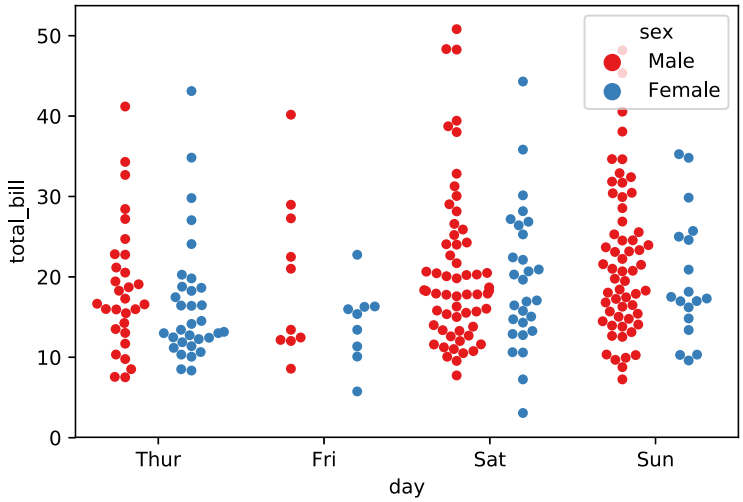

Как говорилась ранее, эти типы графиков можно комбинировать с другими. Лучше всего это делать с violinplot.

```
sns.violinplot(x="tip", y="day", data=tips, palette='rainbow')
sns.swarmplot(x="tip", y="day", data=tips, color='black', size=3);
```

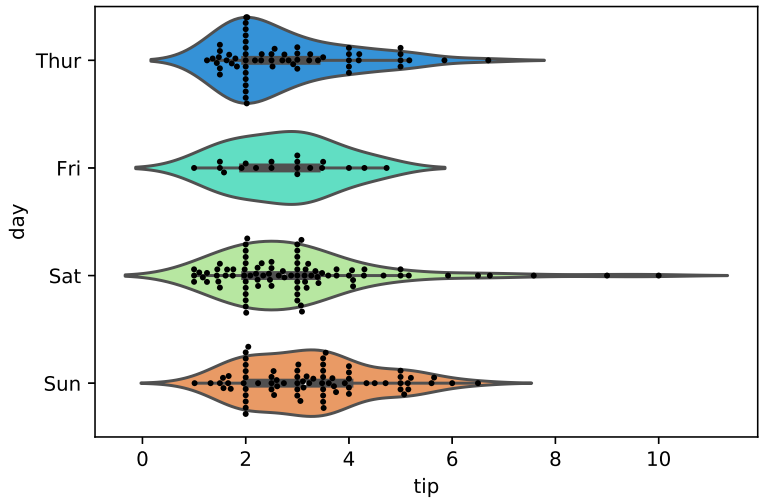

catplot (ранее factorplot)

Из документации: The default plot that is shown is a point plot, but other seaborn categorical plots can be chosen with the `kind` parameter, including box plots, violin plots, bar plots, or strip plots.

```
sns.catplot(x='sex', y='total_bill', data=tips, kind='bar');
```

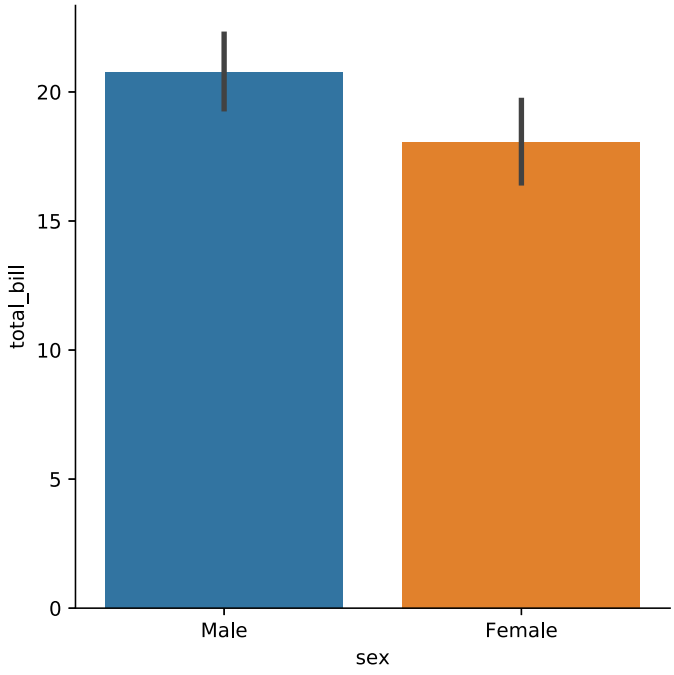

Матричные графики

Тепловая карта

```
tips.corr()
```

	total_bill	tip	size
total_bill	1.000000	0.675734	0.598315

	total_bill	tip	size
tip	0.675734	1.000000	0.489299
size	0.598315	0.489299	1.000000

```
sns.heatmap(tips.corr());
```

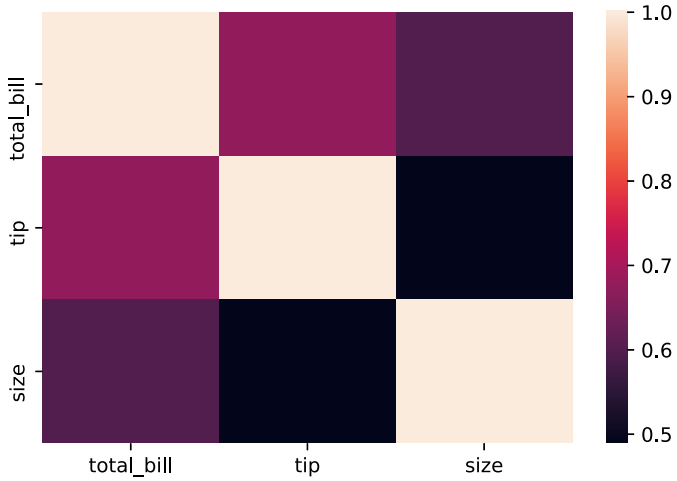


```
sns.heatmap(tips.corr(),cmap='coolwarm',annot=True);
```

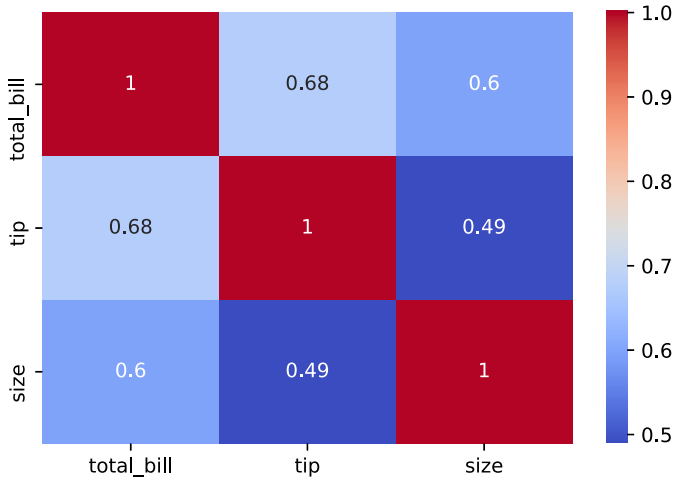

Загрузим данные о полётах:

```
flights = sns.load_dataset('flights');
```

```
flights.head()
```

	year	month	passengers
0	1949	January	112

	year	month	passengers
1	1949	February	118
2	1949	March	132
3	1949	April	129
4	1949	May	121

Посчитаем таблицу сопряжённости, которая покажет, какое количество пассажиров летало в различные месяцы в каждый из годов в промежутке от 1949 по 1960.

```
flights.pivot_table(values='passengers', index='month', columns='year')
```

year	1949	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959
month											
January	112	115	145	171	196	204	242	284	315	340	360
February	118	126	150	180	196	188	233	277	301	318	342
March	132	141	178	193	236	235	267	317	356	362	406
April	129	135	163	181	235	227	269	313	348	348	396
May	121	125	172	183	229	234	270	318	355	363	420
June	135	149	178	218	243	264	315	374	422	435	472
July	148	170	199	230	264	302	364	413	465	491	548
August	148	170	199	242	272	293	347	405	467	505	559
September	136	158	184	209	237	259	312	355	404	404	463
October	119	133	162	191	211	229	274	306	347	359	407
November	104	114	146	172	180	203	237	271	305	310	362
December	118	140	166	194	201	229	278	306	336	337	405

```
pvflights = flights.pivot_table(
    values='passengers', index='month', columns='year')
sns.heatmap(pvflights);
```

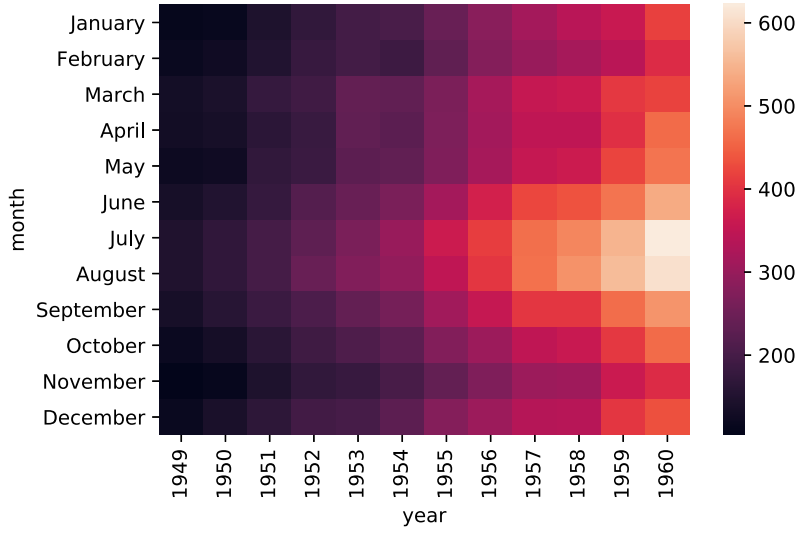


```
sns.heatmap(pvflights,cmap='magma',linecolor='white',linewidths=1);
```

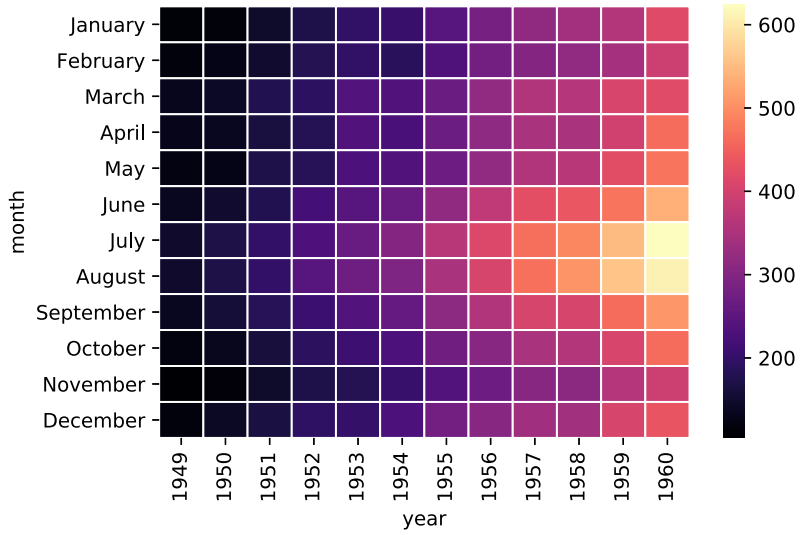

clustermap

Использует алгоритмы иерархической кластеризации для создания визуализации. Можно задавать различные методы кластеризации. Документация.

```
sns.clustermap(pvflights);
```

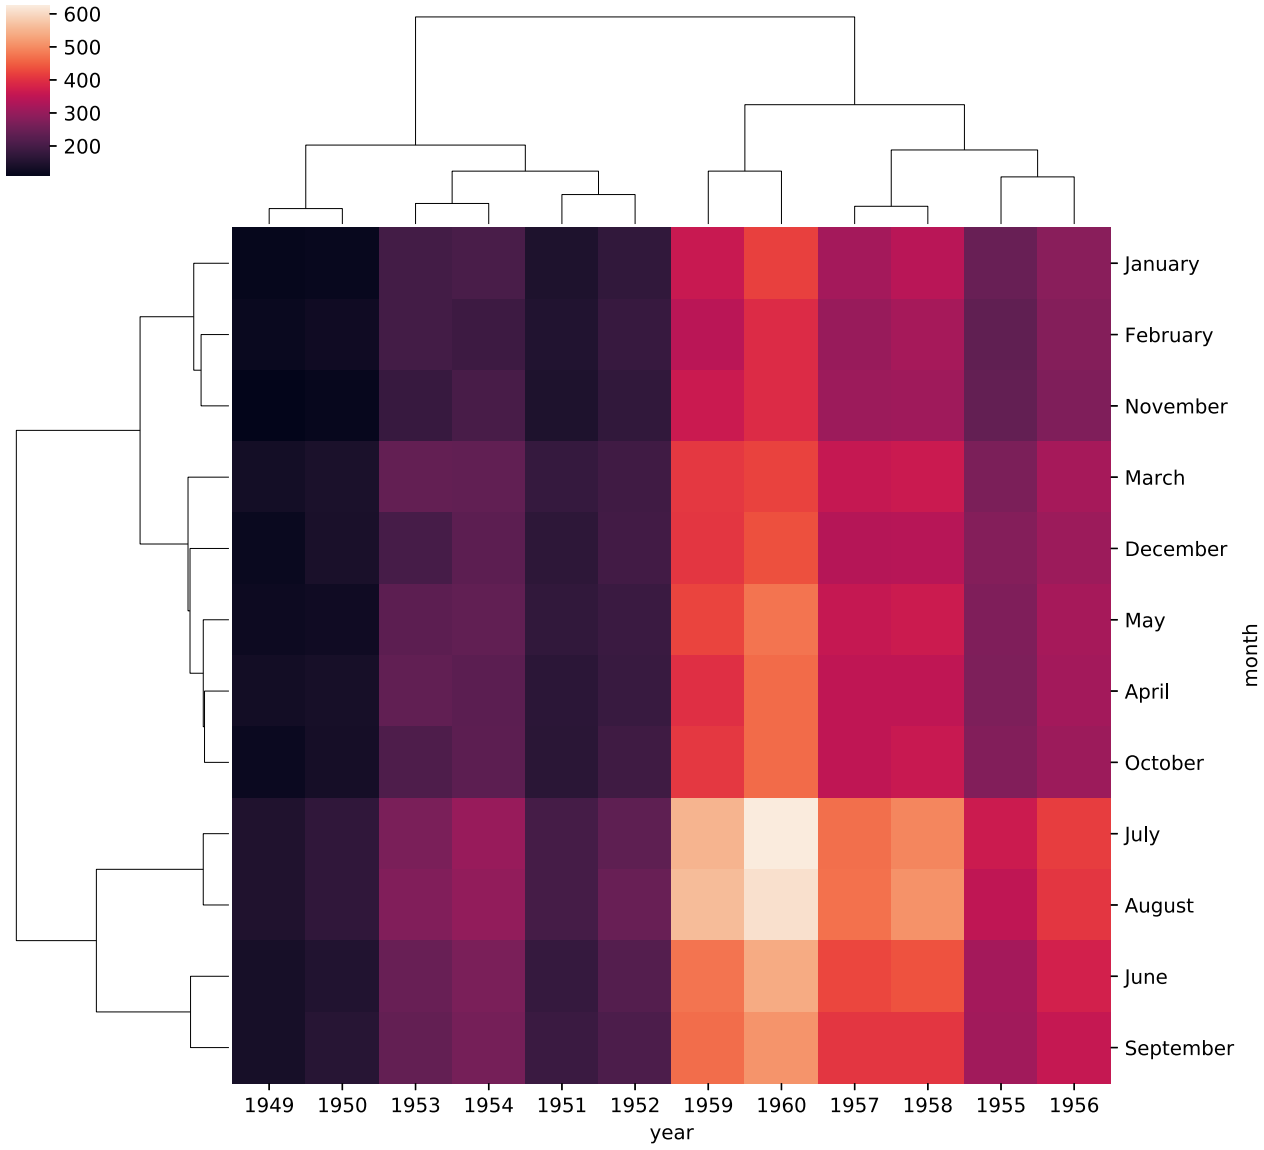

Стили графиков

```
sns.countplot(x='sex', data=tips);
```

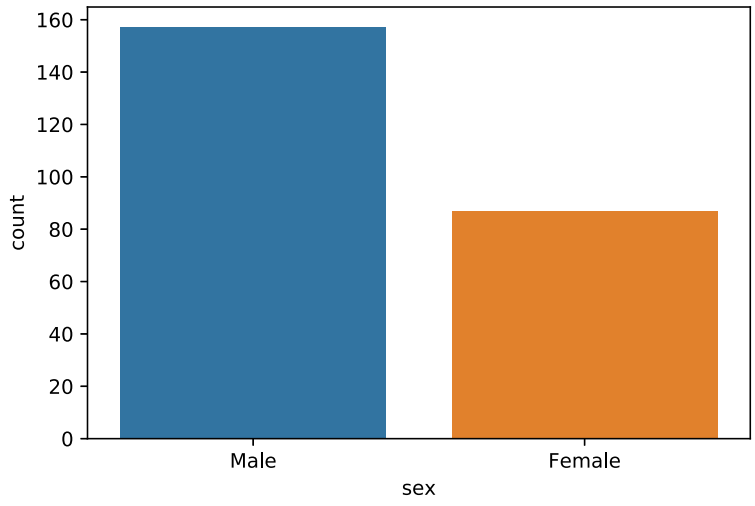


```
sns.set_style('whitegrid')  # Другие значения: darkgrid, whitegrid, dark, white, ticks
sns.countplot(x='sex', data=tips);
```

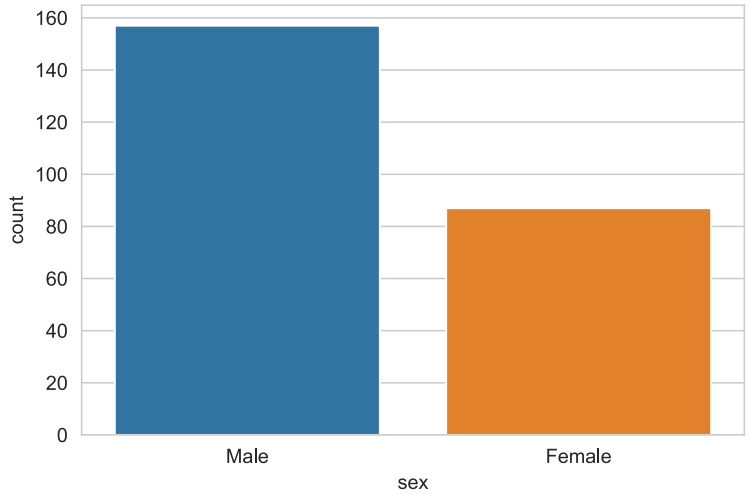


```
sns.set_style("ticks", {"xtick.major.size": 18, "ytick.major.size": 18})
sns.countplot(x='sex', data=tips);
```

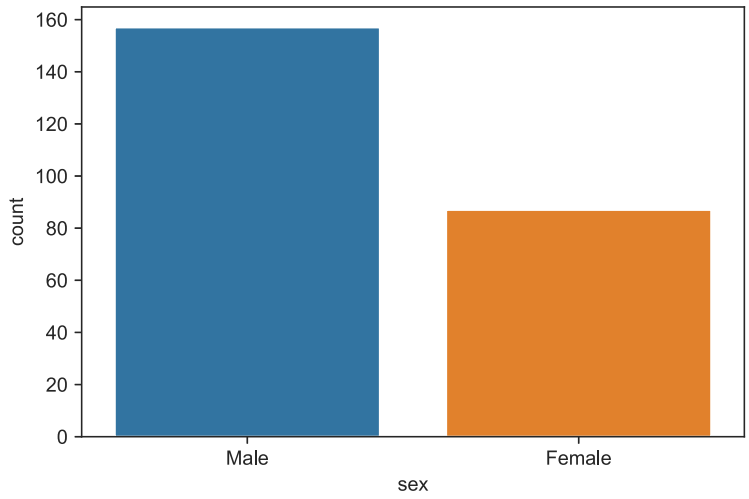

Все переметры стиля можно посмотреть следующим образом:

```
sns.axes_style()
```

Code output

```
{'axes.facecolor': 'white',
'axes.edgecolor': '.15',
'axes.grid': False,
'axes.axisbelow': True,
'axes.labelcolor': '.15',
'figure.facecolor': 'white',
'grid.color': '.8',
'grid.linestyle': '-',
'text.color': '.15',
'xtick.color': '.15',
'ytick.color': '.15',
'xtick.direction': 'out',
'ytick.direction': 'out',
'lines.solid_capstyle': 'round',
'patch.edgecolor': 'w',
'image.cmap': 'rocket'
```

Если необходимо применить стиль только к одному графику, для этого следует использовать менеджер контекста with

```
with sns.axes_style("dark"):
    sns.countplot(x='sex', data=tips);
```

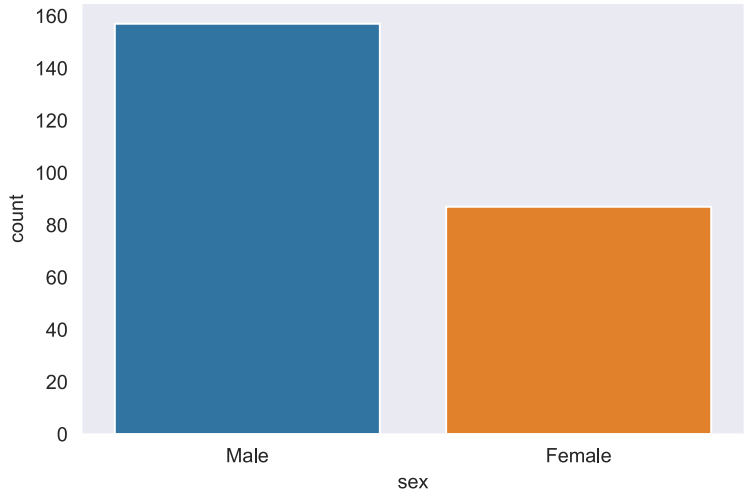

Можно удалить линии осей при помощи метода despine

```
sns.countplot(x='sex',data=tips)
sns.despine(left=True)
```

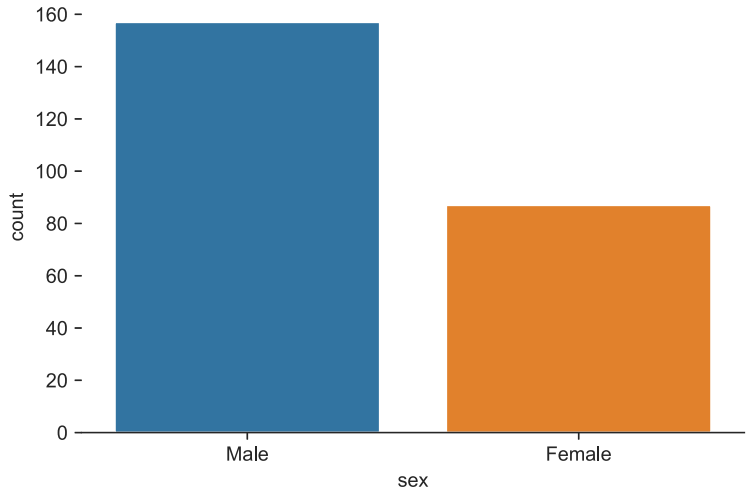

Размеры задаются так же, как и в обычном matplotlib.

```
plt.figure(figsize=(12, 3))
sns.countplot(x='sex', data=tips);
```

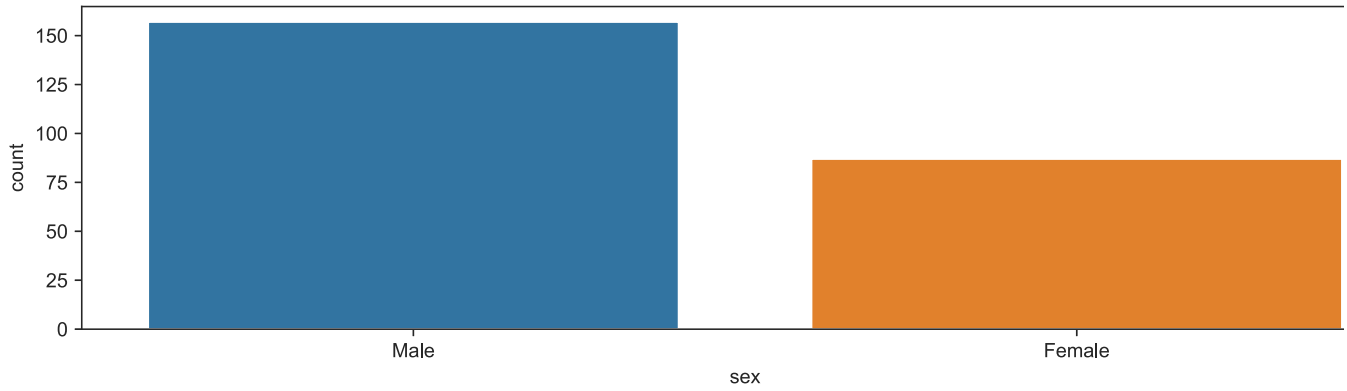


```
sns.lmplot(x='total_bill', y='tip', size=4, aspect=2, data=tips);
```

Code output

```
/usr/local/lib/python3.7/site-packages/seaborn/regression.py:546:
UserWarning: The `size` paramter has been renamed to `height`; please update
your code.
warnings.warn(msg, UserWarning)
```

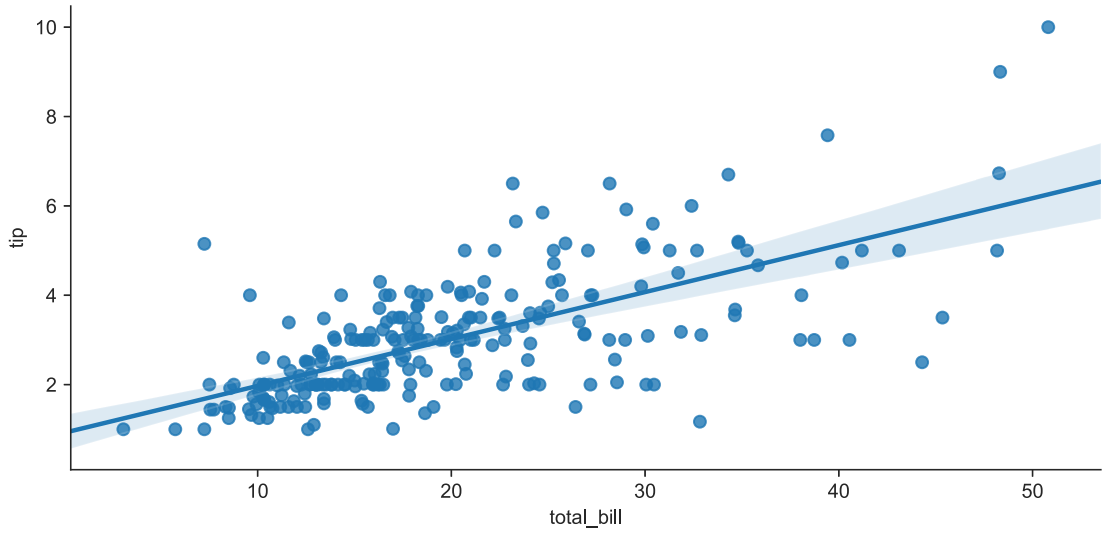

Использование Seaborn совместно с matplotlib

```
fig, ax = plt.subplots()
sns.regplot("tip", "total_bill", data=tips, ax=ax)
ax.set_title("Заголовок")
plt.xlabel('Чаевые')
fig.savefig("filename.png", dpi=200)
```

Code output

```
/usr/local/lib/python3.7/site-packages/scipy/stats/stats.py:1713:
FutureWarning: Using a non-tuple sequence for multidimensional indexing is
deprecated; use `arr[tuple(seq)]` instead of `arr[seq]`. In the future this
will be interpreted as an array index, `arr[np.array(seq)]`, which will
result either in an error or a different result.
return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval
```

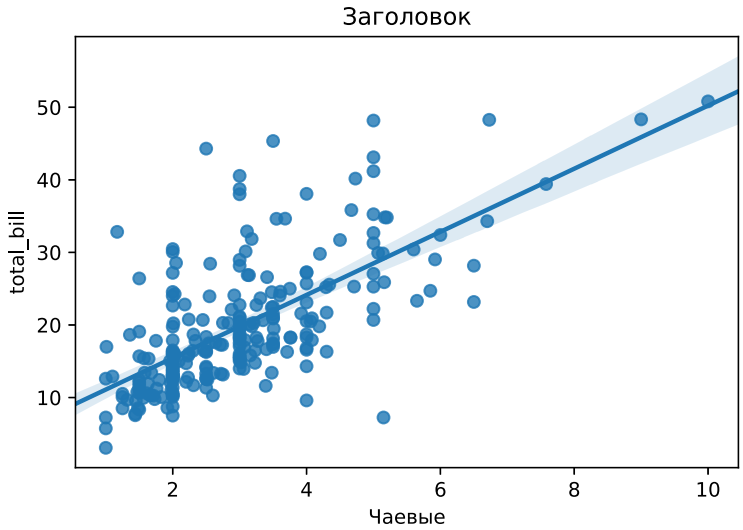

Комментарии

Показать комментарии